



Instituto Federal de Goiás
Câmpus Goiânia

Disciplina de Inteligência em Negócios
Dos Sistemas Transacionais ao Big Data

Sirlon Diniz de Carvalho – Dr
sirlondiniz@gmail.com

 **INSTITUTO FEDERAL**
Goiás

1



Programa Data Warehouse

DW: Histórico e Fundamentos

- . O que é um Sistema Transacional
- . Tipos de Bancos de Dados
- . Modelagem de dados e normalização
- . Desafios para TI
- . Problemas de temporariedade
- . Problemas decorrentes de modelos transacionais
- . Entendendo o negócio a partir dos dados
- . Abordagens de DW
- . Exemplos de Data Mart
- . Arquitetando o DW
- . Estimando custos
- . Abordagem de Data Marts Independentes

Data Warehousing (DWing)

- . Definindo arquiteturas de Data Warehouse
- . Modelagem Iterativa Incremental
- . Problemas de Integração

- . Problemas com origem
- . ETL – Extract Transform Load
- . Dados Externos
- . Metadados: conceitos e modelagem
- . Data Marts virtuais
- . Conceito Multidimensional
- . Esquema Estrela – Star Acheme
- . Modelo Flocos de Neve – Snow Flake
- . Tabelas de Agregação
- . Importância da dimensão tempo

Data Warehouse e a tomada de Decisão

- . DW está pronto e agora
- . Ferramentas de BI
- . Ferramentas Integradas de BI e DW
- . Estudos de Caso
- . Nova fonte de recurso para o negócio
- . Exercício e avaliação

 **INSTITUTO FEDERAL**
Goiás

2

Bibliografia

INMON, W. H., Como Construir o Data Warehouse, Campus, 1997.
 TROISE, M. A. Implementando Data Warehouse e Datamarts. Apresentação Oracle.
 COREY, M., ABBEY, M., ABRAMSON, I. e TAUB, B. Oracle 8i Data Warehouse. Rio de Janeiro, Campus.
 BARBIERI, Carlos. BI – Business Intelligence – Modelagem & Tecnologia. Rio de Janeiro: Editora Axel Books, 2001.
 SERRA, L., A Essência do Business Intelligence, Berkeley Brasil, 2002.
 KIMBALL, Ross. "The Data Warehouse Toolkit: The Complete Guide to Dimensional Modeling (Second Edition)", Wiley, 2002
 DAVENPORT, T. H. Big Data no trabalho; Rio de Janeiro: Alta BookS, 2017.
 GOMES, E.; BRAGA, F. Inteligência Competitiva em tempos de Big Data - Analisando informações e identificando tendências; Rio de Janeiro: Alta Books, 2017.
 SILVA, L. N. C.; FERRAR, D. G.; QUERO, P. Introdução à Mineração de Dados - Conceitos Básicos, Algoritmos e Aplicações; São Paulo: Saraiva, 2016.



3

Principais Tipos de Sistemas de Informação

- Sistemas de Processamento de Transações (TPS)
- Sistemas de Informação Gerencial (MIS)
- Sistemas de Apoio à Decisão (DSS)
- Sistemas de informação executiva (EIS) ou sistemas de suporte executivo (ESS)
- Sistemas de Informações Geográfica (GIS)
- Sistemas de planejamento de recursos empresariais (ERP)
- Sistemas de gestão de relacionamento com o cliente (CRM)
- Sistemas de gestão da cadeia de suprimentos (SCM)
- Sistemas de Gestão do Conhecimento (KMS)



4



5

Aplicações Operacionais ou Transacionais

- Aplicações críticas – OLTP
- Execução do negócio
- Exemplos: Sistemas de controle de vendas de mercadorias, controle de estoque, bancário, financeiros etc.
- Tipos de operações/manipulação de dados (insert, update, delete), normalmente on-line e em nível detalhado.


INSTITUTO FEDERAL
Goiás

6

Como armazenar dados Operacionais

- Textos
- Sistemas de Gerenciamento de Arquivos
- Planilhas eletrônicas
- Sistemas de Gerenciamento de Bancos de Dados

- SGBD Relacional
- SGBD Orientado a Objetos, NoSQL?




7


Modelagem dos dados de aplicações transacionais

Para armazenar é necessário modelar ou projetar o BD

- Normalização
- Porque normalizar
- 1ª, 2ª, 3ª e 4ª FN
- Exemplo de normalização
- Exercício modelagem



8



9

Novas Demandas de T.I.

- Relatórios gerenciais: clientes por bairro, estado civil etc.
- Análise complexa — questões impossíveis de se prever
- Mais demandas para o departamento de T.I.
- Case supermercado — produtos por grupo
- Mas resumo não contradiz normalização?
- Ambiente de negócio em mudança constante
- Dados heterogêneos e inconsistentes



10

Atividades Prática em Laboratório

- Revise as quatro Formas Normais (FN)
- Faça a modelagem de dados do problema proposto em sala (na 4ª FN)
- Proponha e modele pelo menos três relatórios gerenciais que possam ser extraídos do modelo





11

Problemas da modelagem transacional

- Alto volume de dados e necessidade de resposta rápida
- Dados são voláteis: clientes mudam, casam, estudam etc.

Enfim:

Os modelos de dados tradicionais acabam sendo muito complexos e difíceis de ser entendidos pelo usuário. Além disso, Joins de múltiplas tabelas, frequentemente grandes, são demorados e consomem muitos recursos do sistema.




12

Dúvidas e questionamentos surgem

- Conhecemos o negócio?
- Valor da Tecnologia **versus** valor da Informação
- O que está sendo feito com a memória da organização?
- Relatórios gerenciais com dados voláteis são confiáveis?
- Como resolver esse problema...



INSTITUTO
FEDERAL
Goiás

13

Com Aplicações de Tomada de Decisão

Utilizadas para análise do negócio

- Sistemas de Apoio à Decisão - SAD
- Exige conhecimento do negócio
- Vital para desenvolvimento de estratégias
- Informações para a tomada de decisão: consultas complexas em grandes volumes de dados (p.e. determinar a taxa de crescimento do faturamento nos últimos 5 anos)



INSTITUTO
FEDERAL
Goiás


14

Business Intelligence (BI)

“Refere-se à coleta, organização, análise, compartilhamento e monitoramento de informações para suporte à gestão de negócios.”


Contempla:

- Data Warehouse (DW)
- Data Mining (DM)
- Customer Relationship Management (CRM)
- Ferramentas de Visualização e Análise (OLAP)
- Big Data?



INSTITUTO FEDERAL Goiás

15




16

Nascimento Data Warehouse (DW)

“Data Warehouse é um conjunto de dados:

- orientados a assuntos
- integrados
- não-voláteis
- variáveis com o tempo
- usado no apoio a decisões gerenciais”




William H. Inmon
“Pai do Data Warehousing”

17

Características de um DW

- **Orientado a assuntos:** vendas de produtos a diferentes tipos de clientes, atendimentos e diagnósticos de pacientes etc.
- **Integrado:** diferentes nomenclaturas, formatos e estruturas das fontes de dados acomodadas em um único esquema
- **Não volátil:** somente cargas e leituras, com atualizações apenas periódicas.



18

Conceitos básicos de DW

- **Povoamento:** primeira grande carga
- **Carga:** alimentação periódica dos dados
- **Periodicidade de cargas:** depende do assunto
- **Granularidade:** refere-se ao nível de detalhe

<i>Baixa</i>			
Produto	Data	Qtde	Valor
LHD1	12/7/2025	8	400,00
GarminLH	14/7/2025	15	7500,00
LHD1	16/7/2025	20	1000,00
LHD1	17/7/2025	18	900,00

<i>Alta</i>			
Produto	Data	Qtde	Valor
LHD1	7/2025	46	2300,00
GarminLH	7/2025	15	7500,00

19

DW – Conceitos básicos

- **Séries temporais:** o histórico dos dados por um período de tempo superior ao usual em BDs transacionais permite analisar tendências e mudanças
- **Variável com o tempo:** mantem historicidade

BD
Preços

→

Produto	Preço
Caneta Azul	0,50
Lápis Preto	0,30
...	...

DW
Preços


→

Produto	Jan/03	Fev/03	Mar/03
Caneta Azul	0,40	0,45	0,50
Lápis Preto	0,25	0,28	0,30
...	...	...	...

20

Comparação entre dados transacionais e DW	
Operacionais	Data Warehouse
<i>Orientados à aplicação</i>	<i>Orientados a assuntos</i>
<i>Precisão Instantânea</i>	<i>Snapshots</i>
<i>Atualizáveis</i>	<i>Somente para leitura</i>
<i>Voláteis</i>	<i>Históricos</i>
<i>Dispersos em aplicações</i>	<i>Integrados no DW</i>
<i>Acesso frequente</i>	<i>Acesso esporádico</i>
<i>Acesso a quantidade reduzida</i>	<i>Acesso a grande volume</i>

21



22

Afinal, o que é o DW?


- Um novo modelo de Dados
- Uma nova estrutura de armazenamento
- Infraestrutura diferente
- Acesso diferenciado
- Grandes quantidades de dados



23


DW – Abordagem Organizacional

Sistemas Transacionais




- Dados da empresa com determinado nível de normalização
- Integrador de áreas funcionais
- Alto nível de detalhamento

24



25



26

Data Mart - Aplicação

Data Mart

- Uso departamental
- Locais remotos (filiais, lojas etc.)
- Estatística/Mineração
- Acesso externo (fornecedores, clientes etc.)



27

DWing: Construindo o Data Warehouse

Abordagem Organizacional

- Mapeando e identificando sistemas existentes
- Definindo a equipe:
 - Gerentes de projetos
 - Analistas de negócios
 - Analistas de Sistemas
 - Projeção e custos



28

DW – Abordagem Organizacional

Vantagens

- Evita a repetição de extração
- Garante uma interpretação padronizada dos dados
- Facilidade de se construir novos Data Marts


Desvantagens

- Prazos longos de construção
- Alto custo
- Alto risco



Abordagem Data Marts Independentes

- Proposta por Ralph Kimball
- Objetivo de minimizar os problemas da arquitetura organizacional de Inmon



Abordagem Data Marts Independentes

Vantagens

- Construção rápida
- Menor custo
- Menor risco

Desvantagens


- Extração repetida
- Diferenças de terminologia, semântica e formatos
- Variedade de regras de transformação
- Dificuldade de integração




Sequência Didática: DWing – Projetando o DW

- Abordagem Iterativa Incremental
- Problemas de Integração
- Problemas com origem
- ETL – Extract Transform Load
- Dados Externos
- Metadados: conceitos e funcionalidades
- Modelagem de Metadados
- Exercício modelagem Metadados
- Data Marts virtuais
- Conceito Multidimensional
- Esquema Estrela – Star Acheme
- Modelo Flocos de Neve – Snow Flake
- Tabelas de Agregação
- Importância da dimensão tempo





33



34

A integração esbarra em:

- Tipos de dados heterogêneos, em sistemas diferentes
 - Sexo: masculino/feminino, f/m, 0/1 etc.
- Dados inconsistentes
 - Integridades não garantidas por sistemas legados
- Definição de solução default
- Opção de ignorar o registro
- Alternar fontes de busca
- Algumas perdas são inevitáveis




35

Processo de integração de dados

OPERACIONAL

DATA WAREHOUSE



36

Problemas com Sistemas Legados

- Modelagem inexistente
- Programadores não pertencem mais à equipe
- Sistemas proprietários não possibilitam acesso
- Domínio de tecnologia obsoleta: cobol, adabas etc.
- Dados dependentes da aplicação: difícil dissociar
- Equipe transacional não coesa com B.I.



37

ETL: Desafio da Extração

- “Somente a extração dos dados leva cerca de 60% das horas de desenvolvimento de um DW (KIMBALL, 1998 apud ABREU, 2007).”
- “A maior parte do esforço exigido no desenvolvimento de um DW é consumido neste momento e não é incomum que oitenta por cento de todo esforço seja empregado no processo de ETL, (INMON, 1997 apud ABREU, 2007)”
- A extração é afetada pelo ambiente



38

ETL: Desafio da transformação

“Subsequente à extração, esta fase não só transforma os dados, mas também realiza a limpeza dos mesmos.”

- ✓ Correção de erros de digitação
- ✓ Descoberta de violações de integridade
- ✓ Substituição de caracteres desconhecidos
- ✓ Padronização de abreviações



INSTITUTO
FEDERAL
Goiás

39

“É necessário que os dados fiquem em uma forma homogênea para serem carregados no DW.”

Características para garantir a qualidade dos dados:

- Unicidade: evitar duplicações de informação
- Precisão: dados não podem perder suas características originais
- Completude: não gerar dados parciais de todo o conjunto relevante às análises
- Consistência: fatos devem apresentar consistência com as dimensões que o compõem



Garantia de
Qualidade
Goiás

40

“Os principais tipos de conflitos estruturais são aqueles de domínio de atributo que se caracterizam pelo uso de diferentes tipos de dados para os mesmos campos.”

Conflitos Típicos - diferenças de

- ✓ Unidades: centímetro, polegada
- ✓ Precisão: quantidade de casas decimais
- ✓ Códigos ou expressões: sexo M/F ou 0/1
- ✓ Granularidade: quando horas trabalhadas correspondem a semana ou a mês, mesmo mantendo a mesma unidade
- ✓ Abstração: quando a forma de estruturar uma mesma informação segue critérios diferentes




41

Como Construir ETL

*“Não há regra específica, depende dos ambientes de onde os dados serão extraídos. Deve-se avaliar o custo **versus** benefício de criar todo o processo – hard code.”*

Podem ser desenvolvidas em: C, SQL, XML, Web Service, Java etc.



Extrair	Transformar	Carregar
- Dados operacionais - Dados externos	- Limpar - Reconciliar - Aprimorar - Sumarizar - Agregar	- Organizar - Combinar várias fontes - Popular sob demanda



42

ETL Hard Code: Vantagens

- **Controle:** se você desenvolve, você tem controle do processo
- **Customização:** o código estará disponível para mudanças
- **Convergência com a plataforma tecnológica:** não será necessário adquirir hardware, software ou sistema operacional para a ETL
- **Convivência com o legado:** desenvolvimento interno se adaptará aos sistemas legados e não o contrário para adaptar-se às cargas
- **Suporte:** a construção própria dispensa contratos de suporte e manutenção
- **Depuração:** atividades de DEBUG não vão se deparar com uma parte não "debugável" do código - código disponível



INSTITUTO
FEDERAL
Goiás

43

Ferramentas de ETL: Vantagens

- **Desenvolvimento das cargas:** em ferramenta de ETL é muito mais fácil e rápido
- **Manutenção das cargas:** manutenção mais fácil que em código
- **Desempenho:** utilizam métodos mais performáticos para trabalhar com grandes volumes
- **Execução em paralelo:** possuem recursos de paralelização nativos e facilmente implementáveis
- **Escalabilidade:** podem ser transferidas de servidor mais facilmente e até eventualmente distribuir sua carga entre vários servidores



INSTITUTO
FEDERAL
Goiás

44

Cont. Vantagens Ferramentas de ETL


- **Diversidade de conectores:** a conexão de uma ferramenta de ETL com múltiplas fontes de dados é transparente
- **Separação entre funcionalidade e manipulação de dados:** já possui suas funcionalidades disponíveis (Lookup, Merge, Split, Expressões calculadas etc.)
- **Reusabilidade:** uma carga normalmente pode ser reaproveitada
- **Reinicialização:** possuem a capacidade de reiniciar a carga de onde pararam
- **Manutenção de Metadados:** metadados são gerados e mantidos automaticamente



45

Cont. Vantagens Ferramentas de ETL

- **Documentação:** possuem mecanismos de documentação
- **Maior garantia da qualidade dos dados:** Ferramentas de ETL podem disponibilizar meios para trabalhar a qualidade dos dados através de algoritmos complexos (lógica fuzzy, IA etc.)
- **Auditoria & Tracking:** permite implementar recursos de auditoria e tracking para conhecer de onde veio o registro, que transformações sofreu e como foi carregado
- **Segurança:** permite tornar a segurança mais modular dividindo-se os papéis (criação de cargas, execução de cargas, agendamento etc.)




46

Ferramentas ETL

- Informatica PowerCenter
- Integrate.io
- Fivetran
- Integrador de Dados Oracle
- Cola AWS (AWS Glue)
- Integração de dados Pentaho
- Google Dataflow
- Azure Data Factory
- IBM Cloud Pak para integração
- Qlik

INSTITUTO FEDERAL
Goiás

47



48

Dados Externos

Valor ECONÔMICO *"Dados Externos referem-se a dados essenciais para a tomada de decisão, mas que não fazem parte dos dados originados dos sistemas transacionais."*

- **Exemplos de Dados Externos:** cotação de moeda estrangeira, situações de catástrofe, cenário de mercado etc.
- **Fonte de Dados Externos:** revistas especializadas, jornais, índices governamentais etc.



fipe
Fundação Instituto de Pesquisas Econômicas

INSTITUTO FEDERAL
Goiás

49

Os Metadados: Conceito

"Essencialmente Metadados refere-se a um dicionário de dados, ou seja, dados que mantêm informações sobre outros dados"

- Para cada atributo no DW, há uma entrada no dicionário
- Dados são consultados e atualizados com base nos metadados
- Permite conhecer e entender a estrutura dos dados
- Em BD transacional a semântica está na aplicação



50

Camadas de Metadados

- Operacional: estrutura dos dados operacionais
- DW: orientada por assunto e informa como os dados foram calculados e devem ser interpretados
- Usuário: organiza dados do DW conforme preferências do usuário


final



51

Classificação de Metadados

- Mapeamento:** forma de mapeamento do BD para DW
- Sumarização:** como as granularidades foram aplicadas
- Históricos:** como as estruturas vem mudando
- Padrões de acesso:** mantém informações sobre frequência e tipo de acesso aos dados



52

Classificação de Metadados

- **Miscelânea:** informação de status sobre estágios de desenvolvimento de partes do DW, informações sobre volume dos dados (para estimativas de tempo e recursos) etc.
- **Algoritmos de sumarização:** mostram a relação entre os diferentes níveis de detalhe dos dados, indicando inclusive que nível de sumarização é mais adequado para um dado objetivo



53

Fontes de Metadados


- Repositórios de ferramentas CASE
- Código fonte dos sistemas operacionais
- Documentação do desenvolvimento dos sistemas operacionais
- Entrevistas
- Ambiente do DW: informações como frequência de acesso, em que nível de agregação, tempo de resposta de cada consulta etc.



54

Exemplos de Metadados: Entidades ou tabelas

- **Nome da entidade:** Cliente
- **Alias(es) da entidade:** Conta, Comprador
- **Def. da entidade:** Um cliente é uma pessoa física ou jurídica que já comprou ou poderá vir a comprar produtos e/ou serviços da empresa.
- **Data de criação:** 10/10/2011
- **Última modificação:** 14/10/2011
- **Chave(s):** Código do Cliente
- **Ciclo de atualização:** Extração mensal
- **Ciclo de arquivamento:** Arquivado após 1 ano
- **Data owner:** Departamento de Vendas
- **Padrões de acesso:** Consultas *ad-hoc* e pré-definidas




Exemplos de Metadados: Atributos

- **Nome do atributo:** Nome do Cliente
- **Nome físico:** Nome_cli
- **Alias(es) do atributo:** Nome da conta, Comprador
- **Def. do atributo:** 'Nome do Cliente' é o nome oficial da pessoa ou da empresa.
- **Data de criação:** 10/10/2011
- **Última modificação:** 14/10/2011
- **Origem do dado:** Sistema de pedidos, arquivo de clientes, campo Nome_Conta



Exemplos de Metadados: Atributos

- **Transformação ou Conversão física:** Conversão de 20 para 35 caracteres
- **Sumarização ou Algoritmo de conversão:** Nenhum
- **Tabelas de Referência ou Valores codificados:** Nenhum
- **Default:** Nenhum
- **Múltiplas origens:** Não




57

Exercício de Modelagem de Metadados



Considere um ambiente em que exista vários BDs transacionais e crie um modelo de entidade relacionamento que possibilite um mapeamento simples entre esses sistemas e o ambiente de DW.

58



59

DW – Exemplo de Modelagem e Normalização


- Exercícios de modelagem em sala



60


Data Marts Virtuais

- Usar conceito de dataview
- Voltado para ambientes mais simples




TO
FEDERAL
Goiás


61



62



63



64

Conceito de Modelagem Multidimensional

- Utilizando-se uma única dimensão (Região) para obter a agregação de um fato relacionado (Vendas):

Região	Vendas
Sul	R\$1.552M
Nordeste	R\$1.732M

65

Conceito de Modelagem Multidimensional

- Utilizando-se duas dimensões (Região e Tempo) para obter a agregação de um fato relacionado

Região	Trimestre	Vendas
Sul	T1	R\$ 377M
	T2	R\$ 368M
	T3	R\$ 423M
	T4	R\$ 355M
Nordeste	T1	R\$ 577M
	T2	R\$ 378M
	T3	R\$ 640M
	T4	R\$ 660M

66

Conceito de Modelagem Multidimensional

- Cada nova dimensão aumenta o nível de detalhe. Acrescentando-se uma quarta dimensão (Cliente) é possível analisar as Vendas por Cliente, por Linha de produtos, por Trimestre, por Região.

Região	Trimestre	Linha de Produtos	Vendas
Sul	T1	Padrão	R\$ 250M
		Especial	R\$ 127M
	T2	Padrão	R\$ 225M
		Especial	R\$ 143M
	T3	Padrão	R\$ 275M
		Especial	R\$ 148M
	T4	Padrão	R\$ 253M
		Especial	R\$ 131M
Nordeste	T1	Padrão	R\$ 280M
		Especial	R\$ 147M
	T2	Padrão	R\$ 255M
		Especial	R\$ 163M
	T3	Padrão	R\$ 305M
		Especial	R\$ 148M
	T4	Padrão	R\$ 283M
		Especial	R\$ 151M

INSTITUTO
FEDERAL
Goiás

67

Conceito de Modelagem Multidimensional

- Visão Multidimensional

Região	Trimestre	Linha de Produtos	Vendas
Sul	T1	Padrão	R\$ 250M
		Especial	R\$ 127M
	T2	Padrão	R\$ 225M
		Especial	R\$ 143M
	T3	Padrão	R\$ 275M
		Especial	R\$ 148M
	T4	Padrão	R\$ 253M
		Especial	R\$ 131M
Nordeste	T1	Padrão	R\$ 280M
		Especial	R\$ 147M
	T2	Padrão	R\$ 255M
		Especial	R\$ 163M
	T3	Padrão	R\$ 305M
		Especial	R\$ 148M
	T4	Padrão	R\$ 283M
		Especial	R\$ 151M


Dimensões

Fatos

INSTITUTO
FEDERAL
Goiás

68


Data Mart - Modelagem Star Scheme



69

Tabela de Fatos

- Contém chaves estrangeiras das tabelas de dimensão
- Armazenam os “números” da empresa
- Cada conjunto de “fatos” é baseado na interseção de cada combinação dos atributos dimensionais



70


Características das Tabelas de Fatos

- Normalizadas
- Grande número de linhas
- Nível de granularidade: o nível de detalhes capturado em uma tabela de fatos
- Ex.: As vendas serão demonstradas diariamente, semanalmente ou mensalmente?
- Recomendação [CAAT01]: armazenar os dados no nível mais detalhado possível

71

71

Data Mart:
– Fato
– Dimensao




72


Características das Tabelas de Dimensão

- Desnormalizadas
- Largas (nº de colunas)
- Mais curtas que as tabelas de fatos
- Usam chaves substitutas
- Devem conter referências aos registros correspondentes nas tabelas de origem
- Contêm campos de data de atualização e de flag de validade


Data Mart - Modelagem Snow Flake

- Vantagem: diminuição da redundância nas tabelas de dimensão
- Desvantagem: necessidade da execução de junções
- Acrescenta estruturas hierárquicas ao Esquema Star





75



76

A Dimensão Tempo

- A dimensão tempo deve ser capaz de expressar o momento em que o dado foi gerado, considerando todas as informações que possam auxiliar no processo de tomada de decisão.

Data

Id Data

Dia da Semana

Dia do mês

Mês

Trimestre

Ano

Data Juliana

Flag de Feriado

Flag de dia útil

Flag de fim-de-semana

Flag de último dia do mês

Estação

Evento



77

Data Warehouse e a tomada de Decisão

- DW está pronto e agora
- Ferramentas de BI
- Ferramentas Integradas de BI e DW
- Estudos de Caso
- Nova fonte de recursos para o negócio
- Exercício e avaliação




78

DW: possível equipe

Função	Responsabilidades
Gerente da data warehouse	Definição das estratégias, planejamento e gerenciamento
Arquiteto de dados	Análise dos requisitos de dados, modelagem de dados e definição de visões
Administrador de metadados	Definição dos padrões de metadados e gerenciamento do catálogo de metadados
Administrador do BD	Criação das estruturas físicas e monitoramento da carga de dados e desempenho das consultas
Usuário de nível gerencial	Descrição dos dados necessários, especificação das regras do negócio e teste dos resultados
Analista de suporte à decisão	Desenvolvimento de aplicações de suporte à decisão
Especialista em aplicações OLTP	Ajuda na localização dos dados e uso dos recursos de consulta (<i>dump</i>) nos sistemas transacionais
Analista e programador de conversões	Indicação e catalogação das fontes de dados e desenvolvimento de programas para carga de dados
Especialista em suporte técnico	Atividades técnicas como instalação e configuração de hardware e software
Instrutor	Treinamento dos usuários para utilização da data warehouse

GoIás

79

Estudos de Caso


DW Produção de Frutas no Brazil

(Carlos Meira, Embrapa, 2003)

Product	Local	Planted Area (ha)		Production		Unity
		2001	2002*	2001	2002*	
Orange	Brazil	825.228	828.437	16.983.436	18.931.919	tons
	Center	9.289	9.921	131.289	145.866	
	North	18.280	16.724	252.317	233.539	
	North-East	109.584	111.233	1.530.322	1.731.698	
	South	52.003	49.210	795.326	740.559	
	South-East	636.072	641.349	14.250.578	16.080.257	
	Espírito Santo	2.735	2.752	29.343	29.907	
	Minas Gerais	43.895	43.418	575.590	599.999	
	Rio de Janeiro	7.955	7.121	115.753	104.501	
	São Paulo	581.487	588.058	13.529.892	15.345.850	
Banana	Brazil	510.313	523.757	6.177.293	6.455.067	tons
Coconut	Brazil	275.551	273.306	1.420.547	1.811.773	10 ³ fruits
Pineapple	Brazil	63.282	64.150	1.468.897	1.450.033	10 ³ fruits
Papaya	Brazil	30.733	31.080	722.986	857.824	tons

* Estimation by December 2002 (actual production data not available yet)


80



81



82



83

Tarefas Realizadas por Técnicas de Mineração de Dados		
TAREFA	DESCRIÇÃO	EXEMPLOS
Classificação	Constrói um modelo de algum tipo que possa ser aplicado a dados não classificados a fim de categorizá-los em classes	?? Classificar pedidos de crédito ?? Esclarecer pedidos de seguros fraudulentos ?? Identificar a melhor forma de tratamento de um paciente
Estimativa (ou Regressão)	Usada para definir um valor para alguma variável contínua desconhecida	?? Estimar o número de filhos ou a renda total de uma família ?? Estimar o valor em tempo de vida de um cliente ?? Estimar a probabilidade de que um paciente morrerá baseando-se nos resultados de diagnósticos médicos ?? Prever a demanda de um consumidor para um novo produto
Associação	Usada para determinar quais itens tendem a co-ocorrerem (serem adquiridos juntos) em uma mesma transação	?? Determinar quais os produtos costumam ser colocados juntos em um carrinho de supermercado
Segmentação (ou Clustering)	Processo de partição de uma população heterogênea em vários subgrupos ou grupos mais homogêneos	?? Agrupar clientes por região do país ?? Agrupar clientes com comportamento de compra similar ?? Agrupar seções de usuários Web para prever comportamento futuro de usuário
Sumarização	Envolve métodos para encontrar uma descrição compacta para um subconjunto de dados	?? Tabular o significado e desvios padrão para todos os itens de dados ?? Derivar regras de síntese

84

Técnicas de Mineração de Dados			
TÉCNICA	DESCRIÇÃO	TAREFAS	EXEMPLOS
Descoberta de Regras de Associação	Estabelece uma correlação estatística entre atributos de dados e conjuntos de dados	?? Associação	Apriori, Apriori-Tid, AprioriHybrid, AIS, SETM (Agrawal e Srikant, 1994) e DHP (Chen et al, 1996).
Árvores de Decisão	Hierarquização dos dados, baseada em estágios de decisão (nós) e na separação de classes e subconjuntos	?? Classificação ?? Regressão	CART, CHAID, C5.0, Quest (Two Crows, 1999); ID-3 (Chen et al, 1996); SLIQ (Metha et al, 1996); SPRINT (Shafer et al, 1996).
Raciocínio Baseado em Casos ou MBR	Baseado no método do vizinho mais próximo, combina e compara atributos para estabelecer hierarquia de semelhança	?? Classificação ?? Segmentação	BIRCH (Zhang et al, 1996); CLARANS (Chen et al, 1996); CLIQUE (Agrawal et al, 1998).
Algoritmos Genéticos	Métodos gerais de busca e otimização, inspirados na Teoria da Evolução, onde a cada nova geração, soluções melhores têm mais chance de ter “descendentes”	?? Classificação ?? Segmentação	Algoritmo Genético Simples (Goldberg, 1989); Genitor, CHC (Whitley, 1993); Algoritmo de Hillis (Hillis, 1997); GA -Nuggets (Freitas, 1999); GA -PVMINER (Araújo et al, 1999).
Redes Neurais Artificiais	Modelos inspirados na fisiologia do cérebro, onde o conhecimento é fruto do mapa das conexões neuronais e dos pesos dessas conexões	?? Classificação ?? Segmentação	Perceptron, Rede MLP, Redes de Kohonen, Rede Hopfield, Rede BAM, Redes ART, Rede IAC, Rede LVQ, Rede Counterpropagation, Rede RBF, Rede PNN, Rede Time Delay, Neocognitron, Rede BSB (Azevedo, 2000), (Braga, 2000), (Haykin, 2001)

85

Regras de Associação

1. **PAGODE, SERTANEJO, CLÁSSICO, SAMBA**
2. **CLÁSSICO, SAMBA**
3. **PAGODE, SERTANEJO, CLÁSSICO, SAMBA**
4. **SERTANEJO, CLÁSSICO, SAMBA**
5. **SAMBA**
6. **CLÁSSICO**
7. **PAGODE, CLÁSSICO, SERTANEJO, SAMBA**
8. **SERTANEJO, CLÁSSICO, SAMBA**
9. **PAGODE, SERTANEJO, CLÁSSICO, SAMBA**
10. **PAGODE, SERTANEJO, CLÁSSICO, SAMBA**

Pagode aparece em 5 das 10 das transações (aleatoriamente seria a minha probabilidade de achar pagode numa venda) $5/10 = 50\%$
 Pagode aparece em quatro das seis transações, com sertanejo (agora a probabilidade que existe com a associação com sertanejo) $4/6 = 67\%$
 $Lift = 67/50 = 1,34$
 Esse valor indica quantas vezes a associação com sertanejo aumenta a probabilidade de vender pagode. Ou seja, nessa amostra há indicação de que existe 1,34 vez mais chance de vender pagode quando associado a sertanejo.

Probabilidade sertanejo e pagode

<u>Confiança</u>	<u>Suporte</u>
$4/6=67\%$	$4/10=40\%$


INSTITUTO FEDERAL
 Goiás **86**

86

Nova Fonte de Recursos para a empresa

- Questões éticas
- A Informação como ativo da empresa: novo conceito
- Possibilidade de vendas de informação
- Para onde vamos? Big Data?



FEDERAL
Goiás

87