



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE GOIÁS

PRÓ-REITORIA DE ENSINO

CÂMPUS GOIÂNIA

ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL APLICADA

IGOR COUTINHO FERREIRA NOBRE

Ensemble de Clusterização e Regras de Associação

Segmentação de municípios e descoberta de
padrões de acidentes por cluster, sobre o Data
Mart PRF-DATATRAN

Relatório de Disciplina

Professor: Dr. Sirlon Diniz de Carvalho
Disciplina: Tópicos Avançados em Inteligência Artificial I

Goiânia, 2026.

1 INTRODUÇÃO

Este relatório documenta a atividade da disciplina Tópicos Avançados em Inteligência Artificial I, reproduzida a seguir na íntegra, conforme recebida:

Ensamble (*sic*): clusterização de clientes com Regras de Associação

Combinar clusterização de clientes com Regras de Associação é uma estratégia extremamente poderosa para análises de CRM e marketing. A ideia central é simples: em vez de aplicar as regras de associação em toda a base de transações (o que pode gerar milhares de regras genéricas e pouco acionáveis), você segmenta os clientes primeiro e, em seguida, descobre padrões de compra específicos para cada grupo.

Portanto, de posse do DW Organizacional ou Datamart construído para esse fim, povoar o BD e aplicar o conceito de ensemble (aprendizagem por conjuntos):

- 1) Utilizar dados para clusterizar ou classificar os clientes
- 2) De posse das compras por grupo/classe, aplicar as Regras de Descoberta de Associação entre produtos.

Obs: Para o trabalho pode-se utilizar as ferramentas das bibliotecas Python.

Entregáveis: Código e relatório técnico do processo.

O enunciado chama de *ensemble* a combinação, em sequência, de duas técnicas não supervisionadas: segmentar os clientes antes de minerar regras de associação, em vez de minerar sobre toda a base de uma só vez. É um uso mais amplo do termo, que na literatura designa em geral a combinação das predições de vários modelos (Dietterich, 2000).

1.1 Ambiente construído e adaptação do domínio

Para esta atividade foi construído, do zero, um ambiente sobre os dados abertos de sinistros de trânsito da Polícia Rodoviária Federal (PRF) (Polícia Rodoviária Federal (PRF), 2026): Data Warehouse (DW) Organizacional (Inmon (Inmon, 2005)), Data Mart em estrela (Kimball (Kimball; Ross, 2013)), Extract, Transform, Load (ETL) via Airflow e Business Intelligence (BI) via Metabase (Capítulo 2). Sobre o Data Mart povoado foi aplicado o *ensemble* (Capítulo 3), com resultados no Capítulo 4.

O domínio de origem (acidentes de trânsito) não tem o conceito de *cliente* comprando *produtos*. Os dois conceitos foram adaptados ao domínio disponível,

preservando a mesma estrutura do problema (segmentar, depois minerar regras por segmento):

Quadro 1 – *Adaptação dos conceitos do enunciado ao domínio PRF-DATATRAN*

Enunciado	Adaptado para	Justificativa
Cliente	Município (<code>nome_municipio + sigla_uf</code>)	Unidade geográfica que concentra ocorrências ao longo do tempo; acumula um <i>perfil de risco</i> (letalidade, gravidade, volume, condições predominantes), como um cliente acumula um perfil de compras
Produto (item da cesta de compra)	Cada classificação de uma ocorrência (causa, tipo de acidente, condição meteorológica, fase do dia, tipo de pista, traçado da via, uso do solo, sentido da via, classificação quanto a vítimas)	Uma ocorrência é tratada como uma <i>cesta</i> com até 9 itens, um por tipo de classificação

Fonte: Elaborado pelo autor.


Todo o trabalho (código-fonte e este relatório) está no repositório https://github.com/coutinhonobre/dw_trabalho_apresentacao (Nobre, 2026). O relatório usa o modelo L^AT_EX oficial do IFG, classe-ifg, do Prof. Dr. Raphael de Aquino Gomes (Gomes, 2020).

2 AMBIENTE E DATA MART

Para esta atividade foi construído um ambiente containerizado (*Docker Compose*) em cinco camadas, sobre o conjunto de dados abertos *Sinistros de trânsito agrupados por ocorrência* da Polícia Rodoviária Federal (PRF) (PRF-DATATRAN), publicado no Portal Brasileiro de Dados Abertos (Polícia Rodoviária Federal (PRF), 2026): um Comma-Separated Values (CSV) por ano, 2007 a 2026, uma linha por ocorrência (`app/dataset/`). A camada transacional não existe na origem: foi modelada apenas para abstrair esses arquivos CSV num banco relacional, servindo de fonte para a carga do DW. O Quadro 2 resume as quatro primeiras camadas; a quinta (*Machine Learning*, o foco desta atividade) é detalhada no Capítulo 3.

As três primeiras camadas vivem no mesmo servidor PostgreSQL; a carga do transacional para o DW é feita por duas Directed Acyclic Graph (DAG)s do Apache Airflow (carga inicial e incremental). O Figura 1 mostra o DW Organizacional: por

Figura 1 – Diagrama entidade-relacionamento do DW Organizacional (corporativo)



Fonte: Elaborado pelo autor.

Quadro 2 – Camadas do ambiente construído para esta atividade

Camada	Descrição
1. Transacional	Abstração dos CSV da PRF, normalizada até a 4ª Forma Normal, banco datatran
2. DW corporativo	À Inmon (Inmon, 2005) (por assunto, integrado, não-volátil, variante no tempo), schema corporativo do banco dw
3. Data Mart em estrela	À Kimball (Kimball; Ross, 2013), derivado do corporativo, schema public do banco dw . Base do <i>ensemble</i> (Seção 2.1)
4. BI (Metabase)	Painéis via Application Programming Interface (API), com os cards de clusterização e regras de associação (Seção 4.3)


Fonte: Elaborado pelo autor.

assunto (Tempo, Geografia, Classificação do Acidente, Vítimas, Ocorrências), cada catálogo de classificação em tabela própria e `ocorrencias` como fato operacional.

2.1 Grão e dimensões do Data Mart

Grão de **1 linha por ocorrência**, sem granularidade por vítima ou veículo: `dim_tempo` (calendário), `dim_local` (município, Unidade da Federação (UF), rodovia e *km* numa única linha), `dim_classificacao_acidente` (*dimensão junk* com uma linha por combinação observada de 8 das 9 classificações da ocorrência) e `fato_acidente_tracado_via` (tabela ponte, padrão Kimball, para a 9^a classificação, multivalorada desde 2017). O fato `fato_acidentes` traz `mortos`, `feridos_leves`, `feridos_graves`, `ilesos`, `ignorados` e os totais pré-calculados `feridos/pessoas`. O Figura 2 mostra o diagrama completo, já com `cluster_municipio` e `regra_associacao` (as duas tabelas de resultado do *ensemble*, Seção 3.3).

Figura 2 – Diagrama entidade-relacionamento do Data Mart em estrela



Fonte: Elaborado pelo autor.

2.2 Catálogo de metadados

Um schema `metadados` (Figura 3) documenta a origem e a regra de transformação de cada campo do DW: tabelas/campos do transacional, do corporativo/Data Mart, algoritmos de Extract, Transform, Load (ETL) e a linhagem entre eles. Fica navegável como dicionário de dados num painel próprio do Metabase.

letalidade, taxa de feridos graves, veículos médios, proporções de fim de semana/noite/chuva/pista simples, e concentração da causa principal. As *features* são padronizadas (`StandardScaler`) antes do agrupamento, para que nenhuma domine a distância euclidiana só por estar numa escala maior.

O agrupamento usa **KMeans** (MacQueen, 1967) (`scikit-learn` (Pedregosa *et al.*, 2011)), com k escolhido automaticamente: o pipeline testa k de 2 a 8 e mantém o valor com o maior *silhouette score* (Rousseeuw, 1987), que compara, para cada município, a distância média ao próprio cluster com a distância média ao cluster vizinho mais próximo, sem depender de rótulo verdadeiro. O Código 1 reproduz o núcleo dessa escolha, de `escolher_k_e_clusterizar()`; o modelo final é reajustado com o k escolhido.

Código 1 Escolha de k por silhueta

```

1 def escolher_k_e_clusterizar(perfil: pd.DataFrame, k_fixo: int | None, output_dir: Path):
2     X = StandardScaler().fit_transform(perfil[FEATURES_CLUSTER])
3
4     if k_fixo:
5         melhor_k = k_fixo
6         silhuetas = {}
7     else:
8         silhuetas = {}
9         for k in range(2, 9):
10             km = KMeans(n_clusters=k, random_state=42, n_init=10).fit(X)
11             silhuetas[k] = silhouette_score(X, km.labels_)
12             melhor_k = max(silhuetas, key=silhuetas.get)

```

3.2 Etapa 2: Regras de associação por cluster

As ocorrências de cada cluster viram *cestas*: até 9 itens por ocorrência, um por classificação (`causa=...`, `tipo_acidente=...`, `clima=...`, `tipo_pista=...` etc.); valores não informativos são descartados da cesta. Sobre as cestas de cada cluster roda o **Apriori** (Agrawal; Srikant, 1994) (`mlxtend` (Raschka, 2018)), que encontra os itemsets frequentes e as regras antecedente $\rightarrow$ consequente, filtradas e ordenadas por três métricas: **suporte** (frequência conjunta), **confiança** ($P(\text{consequente} | \text{antecedente})$) e **lift** (razão entre confiança observada e esperada sob independência; $lift > 1$ indica associação positiva).

O Código 2 reproduz o núcleo dessa etapa: cada cluster vira uma matriz *one-hot* de cestas, alimenta o Apriori e, por fim, as regras.

Código 2 Apriori e regras de associação, por cluster

```

1      te = TransactionEncoder()
2      te_ary = te.fit(transacoes).transform(transacoes)
3      df_onehot = pd.DataFrame(te_ary, columns=te.columns_)
4      itemsets = apriori(df_onehot, min_support=min_support, use_colnames=True,
5                          low_memory=True, max_len=max_itemset_len)
6      if itemsets.empty:
7          continue
8
9      regras = association_rules(itemsets, metric="lift", min_threshold=min_lift,
10                               num_itemsets=len(transacoes))
11      regras = regras[regras["confidence"] >= min_confidence]
```

O Código 1 e o Código 2 são excertos; o código completo está em `app/ml/clusterizacao_regras_associacao.py`. Como o *lift* é simétrico, o pipeline mantém só a direção de maior confiança de cada par.

Parâmetros desta execução: ano de 2024 (um ano por vez, pois os 20 anos juntos excedem a memória do Apriori por cluster), mínimo de 30 ocorrências por município, k entre 2 e 8, suporte mínimo 0,05, *lift* mínimo 1,1, confiança mínima 0,30, itemsets de no máximo 2 itens (regras de 1 antecedente para 1 consequente, evitando *supersets* redundantes do mesmo par) e as 15 regras de maior *lift* mantidas por cluster.

3.3 Persistência e disponibilização para o BI

Os resultados são gravados no próprio Data Mart, nas tabelas `cluster_municipio` e `regra_associacao` (Figura 2), e em CSV/PNG em `ml/output/`. O pipeline roda pela Directed Acyclic Graph (DAG) `ml_clusterizacao_regras_associacao` do Airflow, logo após a carga inicial do DW.


4 RESULTADOS

Esta execução do pipeline cobre o ano de 2024. Das ocorrências desse ano, **597 municípios** atingiram o volume mínimo de 30 ocorrências e entraram na clusterização.

4.1 Clusterização dos municípios

A Figura 4 mostra o *silhouette score* testado para k de 2 a 8: o maior valor (aproximadamente 0,160) ocorre em $k = 2$, caindo para todos os demais valores testados, inclusive o segundo melhor, $k = 4$ (aproximadamente 0,143). O pipeline escolheu, portanto, $k = 2$.

Figura 4 – *Silhouette score por k testado (2 a 8), ano de 2024.*



Fonte: Elaborado pelo autor, a partir da saída do pipeline (ml/output/silhouette_por_k.png).

O cluster 0 reúne 297 municípios e o cluster 1, 300: divisão praticamente equilibrada em número de municípios, mas não em perfil de risco nem em volume de ocorrências (Tabela 1).

Tabela 1 – *Perfil médio por cluster de município, ano de 2024 (cluster 0: 297 municípios; cluster 1: 300 municípios)*

Métrica	Cluster 0	Cluster 1
Ocorrências médias/município	52,69	148,50
Taxa de letalidade	4,25%	2,12%
Taxa de feridos graves	12,19%	8,97%
Veículos médios/ocorrência	2,10	1,91
Proporção fim de semana	34,51%	31,69%
Proporção período noturno	5,12%	5,26%
Proporção com chuva	10,10%	12,07%
Proporção pista simples	88,40%	22,87%
Concentração da causa principal	20,90%	21,90%

Fonte: Elaborado pelo autor, a partir de ml/output/clusters_municipios.csv.

- **Cluster 0** ("Maior Letalidade"): **menor** volume médio (52,69 ocorrências/ano), via quase sempre de **pista simples** (88,40%), **maior** taxa de letalidade (4,25%, o dobro do cluster 1) e de feridos graves (12,19%). Perfil associado a vias simples/interestaduais;
- **Cluster 1** ("Menor Letalidade"): **maior** volume médio (148,50/ano, quase $3\times$ o cluster 0), via predominantemente de **pista múltipla** (22,87% de pista simples) e letalidade bem menor (2,12%). Perfil de municípios maiores, com malha viária de maior capacidade.

4.2 Regras de associação por cluster

O cluster 0 reuniu 15.648 ocorrências e o cluster 1, 44.550, bases de transações sobre as quais o Apriori rodou, separadamente. A Figura 5, card do painel do Metabase, lista as cinco regras de maior *lift* de cada cluster ("Maior Letalidade" é o cluster 0, "Menor Letalidade" o cluster 1; suporte e confiança em %). A lista completa, com até 15 regras por cluster, está em `ml/output/regras_associacao_por_cluster.csv`.

Figura 5 – Card "Top Regras de Associação por Cluster" no Metabase

Top Regras de Associação por Cluster

Esta pergunta está escrita em SQL.

rotulo	antecedente	consequente	suporte_pct	confianca_pct	lift	+
Maior Letalidade	causa=Acessar a via sem observar a presença dos outros veículos	tipo_acidente=Colisão Transversal	9.6	76.9	4.28	
Maior Letalidade	tracado_via=Interseção de Vias	tipo_acidente=Colisão Transversal	5.3	62.1	3.45	
Maior Letalidade	tracado_via=Interseção de Vias	uso_solo=Sim	5.4	63.1	2.09	
Maior Letalidade	tipo_acidente=Colisão Transversal	uso_solo=Sim	10.4	58	1.92	
Maior Letalidade	causa=Acessar a via sem observar a presença dos outros veículos	uso_solo=Sim	7.1	56.5	1.87	
Menor Letalidade	causa=Acessar a via sem observar a presença dos outros veículos	tipo_acidente=Colisão Transversal	5.1	59.1	5.24	
Menor Letalidade	causa=Condutor deixou de manter distância do veículo da frente	tipo_acidente=Colisão traseira	5.7	75	3.27	
Menor Letalidade	tipo_acidente=Colisão Transversal	tipo_pista=Simples	5.8	51.6	2.13	
Menor Letalidade	clima=Sol	fase_dia=Pleno dia	5.4	98	1.72	
Menor Letalidade	tipo_acidente=Saída de leito carroçável	uso_solo=Não	8.5	71.7	1.59	

Fonte: Elaborado pelo autor, a partir do Metabase.

A regra de maior *lift* é a mesma nos dois clusters (*causa=Acessar a via sem observar a presença dos outros veículos* → *tipo_acidente=Colisão Transversal*), mas mais forte no cluster 1 (5,24) do que no 0 (4,28), mesmo com suporte menor. As demais regras da Figura 5 aparecem em apenas um dos dois clusters, por exemplo *causa=Condutor deixou de manter distância do veículo da frente* →


tipo_acidente=Colisão traseira (lift 3,27) só no cluster 1, o resultado esperado de minerar regras por segmento em vez de uma única vez sobre a base inteira.

4.3 Painel de BI (Metabase)

As tabelas de resultado alimentam três cards do painel do Metabase: **Municípios por Cluster**, **Perfil de Risco por Cluster (%)** (Figura 6) e **Top Regras de Associação por Cluster** (Figura 5). Os rótulos de cluster são calculados por uma Common Table Expression (CTE) que os ranqueia pela letalidade média a cada execução.


A Figura 7 mostra o painel completo, *"Painel PRF - Acidentes de Trânsito"*. Além dos cards do *ensemble* (no fim da segunda parte), ele traz os indicadores gerais do Data Mart: total de ocorrências, óbitos, feridos e veículos, letalidade, mapa de óbitos por UF, ocorrências por mês e por dia da semana, principais causas, condição meteorológica, fase do dia, rodovias com mais óbitos, tipo de pista e um resumo por UF.

Figura 6 – Card *"Perfil de Risco por Cluster (%)"* no Metabase



Fonte: Elaborado pelo autor, a partir do Metabase.

Figura 7 – Painel PRF - Acidentes de Trânsito no Metabase
(exportação completa: três partes)



Fonte: Elaborado pelo autor, a partir do Metabase.

5 CONCLUSÃO

O *ensemble* pedido foi aplicado sobre o Data Mart construído para esta atividade, com município no papel de cliente e classificações da ocorrência no papel de produto: KMeans ($k = 2$ pela silhueta) para segmentar, depois Apriori dentro de cada segmento.

O resultado foram dois perfis de município distintos e regras próprias de cada

um, que se perderiam rodando o Apriori uma única vez sobre a base inteira. Como limitação, a execução cobriu apenas 2024 (restrição de memória do Apriori com os 20 anos); o mesmo pipeline pode rodar para outros anos e comparar a estabilidade de clusters e regras no tempo.

Referências

AGRAWAL, Rakesh; SRIKANT, Ramakrishnan. Fast algorithms for mining association rules. *In: Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*. Santiago, Chile: [s.n.], 1994. p. 487–499. 8

DIETTERICH, Thomas G. Ensemble methods in machine learning. *In: Multiple Classifier Systems: First International Workshop, MCS 2000*. Berlin: Springer, 2000. (Lecture Notes in Computer Science, v. 1857), p. 1–15. 2

GOMES, Raphael de Aquino. **classe-ifg: modelo de documentos acadêmicos em $\text{\LaTeX}$ do Instituto Federal de Goiás**. 2020. Disponível em: <https://github.com/raphaeldeaquino/classe-ifg>. Acesso em: 07 out 2026. 3

INMON, William H. **Building the Data Warehouse**. 4. ed. Indianapolis: Wiley, 2005. 2, 4

KIMBALL, Ralph; ROSS, Margy. **The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling**. 3. ed. Indianapolis: Wiley, 2013. 2, 4

MACQUEEN, James. Some methods for classification and analysis of multivariate observations. *In: LE CAM, Lucien M.; NEYMAN, Jerzy (Ed.). Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Berkeley: University of California Press, 1967. v. 1, p. 281–297. 8

NOBRE, Igor Coutinho Ferreira. **dw_trabalho_apresentacao: DW, Data Mart e ensemble de clusterização e regras de associação sobre dados da PRF**. 2026. Disponível em: https://github.com/coutinhonobre/dw_trabalho_apresentacao. Acesso em: 07 out 2026. 3

PEDREGOSA, Fabian; VAROQUAUX, Gaël; GRAMFORT, Alexandre; MICHEL, Vincent; THIRION, Bertrand; GRISEL, Olivier; BLONDEL, Mathieu; PRETTENHOFER, Peter; WEISS, Ron; DUBOURG, Vincent *et al.* Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011. 8

Polícia Rodoviária Federal (PRF). **Sinistros de trânsito agrupados por ocorrência**. 2026. Portal Brasileiro de Dados Abertos. Disponível em: <https://dados.gov.br/dados/conjuntos-dados/sinistros-de-transito-agrupados-por-ocorrencia>. Acesso em: 07 out 2026. 2, 3

RASCHKA, Sebastian. MLxtend: Providing machine learning and data science utilities and extensions to Python’s scientific computing stack. **The Journal of Open Source Software**, v. 3, n. 24, p. 638, 2018. 8

ROUSSEEUW, Peter J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53–65, 1987. 8