

RELATÓRIO DE DISCIPLINA

Ensemble de Clusterização e Regras de Associação

Segmentação de municípios e descoberta de padrões de acidentes por cluster, sobre o Data Mart PRF-DATATRAN.

Igor Coutinho Ferreira Nobre

Professor: Dr. Sirlon Diniz de Carvalho

Goiânia, 2026

O PEDIDO

Clusterizar clientes. Depois, regras por grupo.

APRIORI NA BASE INTEIRA

Milhares de regras genéricas

Padrões médios do Brasil inteiro. Pouco acionáveis.

APRIORI DENTRO DE CADA CLUSTER

Regras específicas de cada perfil

Segmentar primeiro, minerar depois. É o ensemble pedido.

A ADAPTAÇÃO

Acidente não tem cliente. Nem produto.

CLIENTE

Município

Acumula um perfil de risco ao longo do tempo, como um cliente acumula um perfil de compras.

PRODUTO

Classificação

Causa, tipo, clima, fase do dia, pista, traçado, uso do solo, sentido, vítimas. Uma ocorrência é uma cesta de até 9 itens.

OS DADOS

PRF-DATATRAN. Dados abertos.

2.237.158

ocorrências em rodovias
federais

20 anos

2007 a 2026, um CSV por
ano

131.220

óbitos registrados

1 linha

= 1 ocorrência, já na fonte

Portal Brasileiro de Dados Abertos. Sinistros agrupados por ocorrência, com contagens de vítimas e veículos por linha.

Cinco camadas. Construídas do zero.

01

Transacional

CSV da PRF num banco normalizado até a 4FN.

02

DW corporativo

Inmon: por assunto, integrado, não volátil, variante no tempo.

03

Data Mart

Kimball, em estrela. É a base do ensemble.

04

BI Metabase

Painéis provisionados via API, com os cards do ML.

05

Machine Learning

KMeans + Apriori, lendo e gravando no Data Mart.

Docker Compose sobe tudo do zero. O Airflow faz a carga inicial, a incremental e dispara o pipeline de ML.

Grão do fato: uma linha, uma ocorrência.

Mesmo grão da fonte

O CSV, o corporativo e o fato têm o mesmo grão. Nada é agregado nem explodido na carga.

Sem grão por vítima ou veículo

A fonte só traz contagens por ocorrência. Um grão mais fino seria inventado.

Medidas somáveis no grão

Mortos, feridos leves e graves, ilesos, veículos. Totais de feridos e pessoas pré-calculados.

O que não cabe no grão vai para fora

8 classificações numa dimensão junk. Traçado da via, multivalorado desde 2017, numa bridge table.


DATA MART

Uma estrela. Três dimensões. Duas tabelas de resultado.

dim_tempo, **dim_local** e **dim_classificacao_acidente** ao redor de **fato_acidentes**.

fato_acidente_tracado_via é a bridge table do atributo multivalorado.

cluster_municipio e **regra associacao** recebem a saída do ensemble, no mesmo schema que o BI Iê.



O pipeline muda de grão duas vezes.



O cluster é decidido no grão de município. As regras são mineradas no grão de ocorrência. A ponte entre os dois é o mapa município → cluster.

ETAPA 1

KMeans nos municípios.

597

municípios com 30 ou mais ocorrências em 2024

2 a 8

valores de k testados, escolha pelo maior silhouette score

k = 2

silhueta 0,160, contra 0,143 do segundo melhor, k = 4

As 9 features de perfil de risco, calculadas por município e padronizadas com StandardScaler:

1 · volume de ocorrências (log)

2 · taxa de letalidade

3 · taxa de feridos graves

4 · veículos por ocorrência


5 · % em fim de semana

6 · % no período noturno

7 · % com chuva

8 · % em pista simples

9 · concentração da causa principal



O que é o KMeans

Não supervisionado: não há rótulo. Agrupa municípios pela semelhança das 9 features.

Como funciona: k centróides; cada município vai para o mais próximo (distância euclidiana); os centróides são recalculados até estabilizar.

k é fixado antes, por isso a silhueta escolhe. **Sensível à escala**, por isso o StandardScaler.

RESULTADO DA ETAPA 1

Dois perfis de município.

Perfil médio por cluster, ano de 2024. Cada métrica é calculada por município e depois tirada a média dos municípios do cluster.

CLUSTER 0 · MAIOR LETALIDADE

297 municípios · 15.648 ocorrências somadas

Ocorrências por município
média dos 297 municípios **52,7**

Taxa de letalidade
óbitos ÷ pessoas envolvidas, média dos municípios **4,25%**

Taxa de feridos graves
feridos graves ÷ pessoas envolvidas, média dos municípios **12,2%**

Pista simples
% das ocorrências em pista simples, média dos municípios **88,4%**

CLUSTER 1 · MENOR LETALIDADE

300 municípios · 44.550 ocorrências somadas

Ocorrências por município
média dos 300 municípios **148,5**

Taxa de letalidade
óbitos ÷ pessoas envolvidas, média dos municípios **2,12%**

Taxa de feridos graves
feridos graves ÷ pessoas envolvidas, média dos municípios **9,0%**

Pista simples
% das ocorrências em pista simples, média dos municípios **22,9%**

ETAPA 2

Apriori, uma vez por cluster.

1 · CESTAS

Cada ocorrência vira até 9 itens:
causa=..., tipo_acidente=..., clima=...
Valores não informativos ficam de fora.

2 · APRIORI

Itemsets frequentes com mlxtend, só nas cestas do cluster. Suporte mínimo 0,05, pares apenas.

3 · REGRAS

Confiança mínima 0,30, lift mínimo 1,1.
As 15 de maior lift por cluster, uma direção por par.

Uma regra é **A → C**: **A é o antecedente** (o item que aparece na cesta) e **C é o consequente** (o item que tende a aparecer junto). **N** é o total de cestas do cluster.

Exemplo real: A = causa=Acessar a via sem observar a presença dos outros veículos, C = tipo_acidente=Colisão Transversal.

Suporte (sup)

$$\text{sup}(A \rightarrow C) = \frac{n(A \cup C)}{N}$$

$n(A \cup C)$ = cestas com A e C juntos, sobre o total N de cestas do cluster.

Confiança (conf)

$$\text{conf}(A \rightarrow C) = \frac{\text{sup}(A \cup C)}{\text{sup}(A)}$$

$P(C | A)$: dado o antecedente, quanto frequente é o consequente.

Lift

$$\text{lift}(A \rightarrow C) = \frac{\text{conf}(A \rightarrow C)}{\text{sup}(C)}$$

Confiança observada sobre a esperada se fossem independentes. Lift > 1: associação positiva.

RESULTADO DA ETAPA 2

Cada cluster tem as suas regras.

Cluster	Antecedente	Consequente	Sup.	Conf.	Lift
Maior Letalidade	causa=Acessar a via sem observar a presença dos outros veículos	tipo_acidente=Colisão Transversal	9,6%	76,9%	4,28
Maior Letalidade	tracado_via=Interseção de Vias	tipo_acidente=Colisão Transversal	5,3%	62,1%	3,45
Maior Letalidade	tipo_acidente=Saída de leito carroçável	tracado_via=Curva	6,1%	34,0%	1,56
Menor Letalidade	causa=Acessar a via sem observar a presença dos outros veículos	tipo_acidente=Colisão Transversal	5,1%	59,1%	5,24
Menor Letalidade	causa=Condutor deixou de manter distância do veículo da frente	tipo_acidente=Colisão traseira	5,7%	75,0%	3,27
Menor Letalidade	causa=Ausência de reação do condutor	tipo_acidente=Colisão traseira	5,2%	33,4%	1,46

Ano de 2024. Seleção da lista de 15 regras por cluster gravada em regra_associacao. Suporte e confiança em %.

Não manter distância leva a colisão traseira. Regra forte num cluster. Ausente no outro.

SEM DICA NENHUMA

23 em 100

dos acidentes do cluster azul são colisão traseira.

COM A DICA: CAUSA = NÃO MANTER DISTÂNCIA

75 em 100


dos acidentes com essa causa são colisão traseira. Isso é a **confiança: 75%**.

ANTES E DEPOIS DA DICA

$75 \div 23 = 3,27$


Isso é o **lift**: a dica deixa a colisão traseira 3,27 vezes mais provável. Lift 1 seria a dica não mudar nada.

No cluster vermelho, de pista simples, essa regra não entra no top 15. Lá aparecem interseção de vias → colisão transversal (lift 3,45) e saída de leito carroçável → curva (1,56). Proporções reais do cluster azul, arredondadas para 100.



BI

O painel lê o mesmo Data Mart.



Como ler o card: cada par de barras é uma métrica do perfil médio do slide anterior, em %. **Vermelho** = Maior Letalidade, **azul** = Menor Letalidade. A barra que salta é Pista Simples: 88% contra 23%. Nas demais, os dois clusters ficam próximos. O rótulo de cada cluster é calculado por uma CTE a cada execução.

CONCLUSÃO

O que fica. O que falta.

Entregue

Data Mart povoado, do CSV ao fato, com ETL no Airflow e grão declarado.

Ensemble aplicado: KMeans com k por silhueta, Apriori dentro de cada cluster.

Dois perfis de município com regras próprias, que se perderiam minerando a base inteira de uma vez.

Limitações e próximos passos

Só 2024: os 20 anos juntos excedem a memória do Apriori por cluster, num único processo Python. Rodar ano a ano e comparar a estabilidade de clusters e regras no tempo.

Deixa para Spark ou Hadoop: KMeans e FP-Growth distribuídos cobririam os 2,2 milhões de ocorrências numa execução só.

Obrigado.

Código, relatório e este ambiente estão no repositório:

github.com/coutinhonobre/dw_trabalho_apresentacao